İSTANBUL ÜNİVERSİTESİ - CERRAHPAŞA

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BİLİŞİM PROJE GELİŞTİRME DERSİ RAPORU

DİYABET YÖNETİM ASİSTANI

Hazırlayanlar:

1306220179 - Ali Akkaya

1306220172 - Ege Uzun

Danışman:

Prof. Dr. RÜYA ŞAMLI

OCAK – 2026

ÖNSÖZ

Diyabet Yönetim Asistanı (Snackabetic) başlıklı bu bitirme projesi, mühendislik disiplini ile sağlık teknolojilerini birleştirerek kronik bir rahatsızlık olan diyabetin yönetimini kolaylaştırmak amacıyla gerçekleştirilmiştir. Günümüzde yapay zekâ teknolojilerinin sağlık alanındaki uygulamalarının artması, bu çalışmanın temel motivasyon kaynağını oluşturmuştur. Bu çalışmanın, diyabet teknolojileri ve yapay zeka alanında yapılacak gelecek çalışmalara ışık tutmasını ve literatüre katkı sağlamasını temenni ederiz.

Bize yol gösteren değerli danışman hocamız Sayın Prof. Dr. Rüya Şamlı'ya ve ailelerimize teşekkürlerimizi sunarız.

Ali Akkaya
Ege Uzun

İçindekiler

ÖNSÖZ **i**

Sembol Listesi **vi**

Kısaltma Listesi **vii**

Özet **viii**

Summary **ix**

1 GİRİŞ **1**

2 GENEL KISIMLAR **3**

2.1 Genel Bilgiler ve Teorik Arka Plan 3

2.1.1 Görüntüden Yemek Tanıma 3

2.1.2 Porsiyon Tahmini ve Besin Değeri Entegrasyonu 3

2.1.3 Sistem Mimarisi ve Bileşenler 4

2.1.4 EfficientNetV2 Mimarisi 4

2.2 Veri Seti 4

2.3 Literatür Taraması 5

2.3.1 Gıda Tanıma (Food Recognition) Alanındaki Gelişmeler 6

2.3.2 Porsiyon Kestirimi ve Hacim Hesaplama Yöntemleri 6

2.3.3 Mobil Diyabet Yönetimi ve Karbonhidrat Sayımı Doğruluğu . . 8

2.3.4 Türk Mutfağına Yönelik Veri Seti Çalışmaları 9

3 KULLANILAN ARAÇ VE YÖNTEM **11**

3.1 Porsiyon Tahmini ve Besin Değeri Entegrasyonu 11

3.2 Veri Seti Oluşturma ve İşleme 12

3.2.1 Veri Elde Edilmesi ve Füzyon Stratejisi 12

3.2.2 Ön İşleme ve Filtreleme 13

3.3 Deneysel Araçlar ve Model Mimarisi 13

3.3.1 Model Seçimi: EfficientNetV2 14

4 TARTIŞMA **15**

5 SONUÇ **16**

ÖZGEÇMİŞ **23**

Şekil Listesi

3.1 Proje Akış Diyagramı 11
3.2 Veri Seti Diyagramı 13

Tablo Listesi

2.1 Kullanılan veri setlerinin genel özellikleri 5
2.2 Gıda Tanıma Odaklı Çalışmaların Karşılaştırılması 6
2.3 Porsiyon Kestirimi Yöntemlerinin Karşılaştırmalı Analizi 7
2.4 Diyabet Uygulamalarının Karbonhidrat Sayım Doğruluğu 8

3.1 Projede kullanılan paketler ve içlerindeki temel sınıflar 14

Sembol Listesi

$Hacim_{Tahmini}$ Tahmin edilen yiyecek hacmi (ml)

$Agirlik_{Tahmini}$ Tahmin edilen yiyecek ağırlığı (g)

$Yogunluk_{Veritabani}$ Besin veritabanından alınan yoğunluk değeri (g/ml)

$Karb_{100g}$ İlgili yiyeceğin 100 gram başına karbonhidrat miktarı (g)

$ToplamKarbonhidrat$ Öğüne ait toplam karbonhidrat miktarı (g)

Kısaltma Listesi

API	Application Programming Interface (Uygulama Programlama Arayüzü)
CNN	Convolutional Neural Network (Evrişimli Sinir Ağı)
IDF	International Diabetes Federation (Uluslararası Diyabet Federasyonu)
IMU	Inertial Measurement Unit (Atalet Ölçüm Ünitesi)
LiDAR	Light Detection and Ranging
MAE	Mean Absolute Error (Ortalama Mutlak Hata)
MFP3D	Monocular Food Portion Estimation in 3D (Tek Görüntüden 3B Porsiyon Kestirimi Yaklaşımı)
PSME	Portion Size Measurement Estimation (Referanssız Porsiyon Boyutu Tahmini)
REST	Representational State Transfer
RGB	Red Green Blue (Kırmızı–Yeşil–Mavi Renk Uzayı)
ToF	Time of Flight (Uçuş Süresi Sensörü)
TURDEP	Türkiye Diyabet Epidemiyolojisi Çalışması
UX	User Experience (Kullanıcı Deneyimi)
ViT	Vision Transformer
GoCARB	GoCARB (Karbonhidrat Tahmini İçin Mobil Sistem)
SNAQ	SNAQ (Diyabet Odaklı Gıda Takip Uygulaması)

Özet

DİYABET YÖNETİM ASİSTANI

Diyabet, dünya genelinde ve ülkemizde hızla artan, yönetimi sadece klinik değil teknoloji destekli mühendislik çözümleri de gerektiren ciddi bir halk sağlığı sorunudur. Hastalığın kontrolü hassas karbonhidrat sayımına bağlı olsa da, hastaların manuel tahmin yöntemleri sıklıkla yüksek hata oranlarına sahiptir ve bu durum sürdürülebilir bir diyabet yönetimini zorlaştırmaktadır. Bu soruna çözüm olarak geliştirilen proje, yapay zekâ destekli teknikler ile besinleri otomatik tanıyarak hata payını minimize etmeyi ve kullanıcı dostu bir karar destek sistemi sunmayı amaçlamaktadır.

Literatür incelendiğinde, mevcut ticari uygulamaların doğruluk oranlarının düşük olduğu, akademik çalışmaların ise kullanıcı deneyimini kısıtlayan referans nesnelere ihtiyaç duyduğu görülmektedir. Ayrıca mevcut modellerin Batı mutfağı odaklı olması nedeniyle karmaşık Türk yemeklerinde yetersiz kalması ve yüksek doğruluklu donanım tabanlı çözümlerin her kullanıcı için erişilebilir olmaması önemli eksikliklerdir.

Bu tez çalışmasında, literatürdeki bu boşlukları doldurmak amacıyla Türk mutfağını da kapsayan birleştirilmiş veri setleri üzerinde eğitilen EfficientNetV2 mimarisi ile erişilebilir ve hibrit bir yaklaşım benimsenmiştir. Porsiyon kestirimi için ise ek donanıma ihtiyaç duymadan tek bir RGB görüntü üzerinden derinlik analizi yapabilen yenilikçi bir öğrenme tabanlı yöntem kullanılmıştır. Elde edilen sonuçlar, sistemin yerel yemekleri yüksek doğrulukla sınıflandırdığını ve klinik olarak kabul edilebilir hata sınırları içerisinde karbonhidrat takibi sağlayarak güvenilir bir medikal asistan potansiyeli taşıdığını göstermektedir.

Summary

DIABETES MANAGEMENT ASSISTANT

Diabetes is a rapidly growing public health issue both globally and locally, requiring technology-supported engineering solutions alongside clinical management. Although disease control depends on accurate carbohydrate counting, patients' manual estimation methods frequently have high error rates, making sustainable diabetes management difficult. Developed as a solution to this problem, this project aims to minimize error margins and provide a user-friendly decision support system by automatically recognizing foods using AI-supported techniques.

A review of the literature reveals that existing commercial applications suffer from low accuracy rates, while academic studies often require reference objects that limit user experience. Furthermore, the inadequacy of existing models for complex Turkish dishes due to their Western-centric focus, and the lack of accessibility for high-accuracy hardware-based solutions, are significant deficiencies.

In this thesis study, an accessible and hybrid approach was adopted using the EfficientNetV2 architecture trained on combined datasets covering Turkish cuisine to fill these gaps in the literature. For portion estimation, an innovative learning-based method capable of performing depth analysis from a single RGB image without the need for additional hardware was utilized. The results demonstrate that the system classifies local dishes with high accuracy and provides carbohydrate tracking within clinically acceptable error limits, indicating its potential as a reliable medical assistant.

1. GİRİŞ

Diyabet, dünya genelinde ve ülkemizde halk sağlığını tehdit eden, görülme sıklığı epidemik boyutlara ulaşan kronik bir metabolizma hastalığıdır. Uluslararası Diyabet Federasyonu (IDF) verilerine göre, 2021 yılı itibarıyla dünya genelinde 537 milyon yetişkin diyabetle yaşamaktadır ve bu sayının 2045 yılına kadar %46 artışla 783 milyona ulaşması öngörülmektedir [1]. Ülkemizdeki durum ise küresel ortalamaların üzerindedir; Türkiye Diyabet Epidemiyolojisi Çalışması (TURDEP-II) sonuçlarına göre, Türkiye'de yetişkin nüfusta diyabet prevalansı 12 yıl içerisinde %7.2'den %13.7'ye yükselerek yaklaşık iki katına çıkmıştır [2]. Bu çarpıcı artış, diyabet yönetiminin sadece klinik bir süreç değil, teknoloji destekli çözümler gerektiren bir mühendislik problemi haline geldiğini göstermektedir.

Diyabet yönetiminin temel taşı, kan şekeri regülasyonunu sağlamak (normoglisemi) adına alınan karbonhidrat miktarının doğru hesaplanmasıdır. Ancak literatürdeki çalışmalar, Tip 1 diyabetli yetişkinlerin öğünlerinin yaklaşık %63'ünde karbonhidrat miktarını yanlış tahmin ettiğini ve hata payının $10g$'ın üzerine çıktığını ortaya koymaktadır [3]. Mevcut yöntemlerin çoğu, hastaların görsel hafızasına ve tecrübesine dayalı manuel tahminlerden oluşmakta, bu da sürdürülebilir ve hassas bir diyabet yönetimini zorlaştırmaktadır [4].

Bu probleme çözüm olarak geliştirilen "Snackabetic: Diyabet Yönetim Asistanı" projesi; yapay zekâ tabanlı görüntü işleme tekniklerini kullanarak besinlerin otomatik tanınmasını ve porsiyon miktarının hesaplanmasını sağlayan bütünleşik bir mobil uygulamadır. Projenin temel amacı; diyabetli bireylerin manuel karbonhidrat sayımındaki hata payını minimize etmek, yerel mutfak kültürüne uygun bir veritabanı sunmak ve ek bir donanım maliyeti gerektirmeyen, kullanıcı dostu bir karar destek sistemi oluşturmaktır.

Literatür incelendiğinde, gıda tanıma ve hacim kestirimi üzerine çeşitli çalışmalar yapıldığı görülmektedir. Foodvisor ve Calorie Mama gibi ticari uygulamalar yaygın olsa da, bu sistemlerin klinik doğruluk testlerinde %30'lara varan hata oranlarına sahip olduğu ve porsiyon kestirimi yapmadan sadece sınıflandırma yaptıkları raporlanmıştır [5, 6]. GoCARB gibi daha gelişmiş akademik çalışmalar, referans nesne (fiducial marker) kullanarak hata payını düşürse de kullanıcı deneyimini kısıtlamaktadır [7].

Mevcut modellerin büyük çoğunluğu Batı mutfağı odaklı Food-101 veri seti üze-

rinde eğitildiğinden [8], Türk mutfağının karmaşık ve çok bileşenli yemeklerini (örneğin; karnıyarık, mantı, dolma) tanımakta yetersiz kalmaktadır [9, 10]. Derinlik sensörü (LiDAR) tabanlı yöntemler %10 altı hata payı ile yüksek doğruluk sunsa da [11, 12], sadece üst segment cihazlarda çalışması teknolojinin erişilebilirliğini engellemektedir [13].

Bu tez çalışmasında, literatürdeki bu boşlukları doldurmak amacıyla hibrit ve erişilebilir bir yaklaşım benimsenmiştir. Gıda tanıma modülü için, yerel temsiliyeti sağlamak adına Turkish Food-102 [14] ve küresel Food-101 veri setleri birleştirilmiş; literatürde yüksek verimliliği kanıtlanmış EfficientNetV2 mimarisi [15, 16] üzerinde eğitilmiştir. Ayrıca benzer görsel özelliklere sahip Asya ve Orta Doğu mutfaklarından elde edilen bulgular da model iyileştirmesinde göz önüne alınmıştır [17, 18].

Porsiyon kestirimi için ise donanım bağımlılığını ortadan kaldıran, tek bir RGB görüntüden derinlik haritası çıkaran (monocular depth estimation) öğrenme tabanlı yenilikçi bir yöntem kullanılmıştır [19, 20]. Bu yaklaşım, ek donanım gerektirmeden 3 boyutlu nokta bulutu (point cloud) analizi yapabilme yeteneğiyle literatürdeki güncel çalışmalara paraleldir [21].

Elde edilen bulgular, geliştirilen sistemin Türk mutfağına özgü yemekleri yüksek doğrulukla sınıflandırabildiğini ve porsiyon kestiriminde referans nesne gerektirmeyen yöntemlere kıyasla rekabetçi sonuçlar ürettiğini göstermektedir. Sisteme entegre edilen monoküler derinlik kestirimi yaklaşımı sayesinde, kullanıcıların ek bir donanıma ihtiyaç duymadan, klinik olarak kabul edilebilir hata sınırları içerisinde (MAE $< 30g$) karbonhidrat takibi yapabilmesi sağlanmıştır. Bu durum, projenin sadece bir kalori sayacı değil, diyabet yönetiminde güvenilir bir medikal asistan olma potansiyelini ortaya koymaktadır.

Raporun organizasyonu şu şekildedir: **Bölüm 2**'de, çalışmanın teorik arka planı, gıda tanıma literatürü, porsiyon kestirim yöntemleri ve diyabet yönetimindeki mevcut teknolojiler detaylıca incelenmiştir. **Bölüm 3**'te, kullanılan veri setlerinin oluşturulması, ön işleme adımları, EfficientNetV2 modelinin eğitim süreçleri ve sistem mimarisi (Mobil ve Backend) açıklanmaktadır. Çalışmamız, elde edilen sonuçların literatürle karşılaştırıldığı ve gelecek çalışmalar için önerilerin sunulduğu **Tartışma ve Sonuç** bölümüyle tamamlanmaktadır.

2. GENEL KISIMLAR

2.1 Genel Bilgiler ve Teorik Arka Plan

Bu bölümde, çalışmanın temelini oluşturan görüntü tabanlı yemek tanıma problemi, kullanılan derin öğrenme yaklaşımı ve sistemin diyabet yönetimi bağlamındaki kullanım amacı özetlenmektedir. Projede amaç; kullanıcının çektiği yemek fotoğrafından yemeği otomatik olarak tanıyarak porsiyon tahmini ile birlikte karbonhidrat ve kalori hesabına girdi sağlayan bir karar destek akışı sunmaktır. Görüntü tabanlı yemek tanıma ve beslenme değerlendirme yaklaşımları, literatürde hem yemek tanıma hem de porsiyon/hacim tahmini boyutlarıyla kapsamlı biçimde ele alınmıştır [10, 13].

2.1.1 Görüntüden Yemek Tanıma

Görüntüden yemek tanıma, bir yemeğe ait fotoğrafın önceden tanımlanmış sınıflardan hangisine ait olduğunun tahmin edilmesi problemidir. Bu problem; farklı ışık koşulları, kamera açısı, arka plan karmaşıklığı, porsiyon farklılıkları ve benzer görünüme sahip yemeklerin ayırt edilmesi gibi zorluklar içerir [10]. Bu çalışmada problem, denetimli öğrenme kapsamında bir çok sınıflı sınıflandırma problemi olarak ele alınmıştır.

Literatürde yemek görüntüsü sınıflandırma probleminde farklı mimarilerin performanslarının karşılaştırıldığı çalışmalar bulunmaktadır [16]. Ayrıca ResNet tabanlı yaklaşımlar [22] ve transfer learning ile ensemble learning kullanan yöntemler [23] literatürde raporlanmıştır. Model, eğitim aşamasında etiketli yemek görüntülerinden sınıfları ayırt etmeyi öğrenir ve tahmin aşamasında her sınıf için bir olasılık değeri üretir. En yüksek olasılığa sahip sınıf, yemek etiketi olarak seçilir.

2.1.2 Porsiyon Tahmini ve Besin Değeri Entegrasyonu

Görüntü tabanlı yemek tanıma sistemlerinin sağlık uygulamalarında etkili kullanılabilmesi için, yalnızca yemek sınıfının belirlenmesi yeterli değildir. Özellikle diyabet yönetimi gibi karbonhidrat takibinin önemli olduğu senaryolarda, yemeğin porsiyon büyüklüğünün tahmin edilmesi ve besin değerleriyle ilişkilendirilmesi gereklidir. Bu nedenle porsiyon tahmini problemi, yemek tanıma sürecinin tamamlayıcı bir bileşeni olarak ele alınmaktadır.

Literatürde porsiyon tahmini, kullanıcıdan ek donanım veya referans nesnesi talep edilmeden gerçekleştirilen referanssız yaklaşımlar üzerinden incelenmektedir. Bu yaklaşımlar, görüntüye dayalı geometrik ipuçları veya mobil cihaz sensör verilerinden yararlanan yöntemleri kapsamaktadır [10, 13]. Elde edilen porsiyon bilgisi, besin veritabanları ile eşleştirilerek kullanıcıya yorumlanabilir karbonhidrat ve kalori çıktıları sunulması hedeflenmektedir.

2.1.3 Sistem Mimarisi ve Bileşenler

Geliştirilen sistem, mobil uygulama ve backend servislerinden oluşan iki katmanlı bir mimariyle tasarlanmıştır. Mobil uygulama (React Native) kullanıcı arayüzünü sağlayarak yemek fotoğrafı çekimi, tahmin sonucunun görüntülenmesi ve öğün kaydı gibi etkileşimleri yönetir. Backend tarafında (Spring Boot) kullanıcı yönetimi, öğün kayıtlarının saklanması, besin/kalori veritabanı ile eşleştirme, karbonhidrat ve kalori hesaplama ile rapor üretimi işlemleri REST servisleri üzerinden gerçekleştirilir.

Yemek tanıma modeli, mobil uygulamadan gelen görüntü üzerinde sınıf tahmini üreterek sistemin hesaplama akışına girdi sağlar. Model çıktısı (yemek etiketi), backend tarafında besin veritabanındaki karşılık gelen kayıt ile eşleştirilir ve porsiyon bilgisiyle birlikte nihai karbonhidrat/kalori sonuçları hesaplanarak mobil uygulamaya iletilir. Görüntü tabanlı yemek tanıma ile birlikte porsiyon ve hacim tahmini bileşenlerinin de sağlık uygulamalarındaki kullanımı literatürde ayrıntılı biçimde incelenmiştir [13].

2.1.4 EfficientNetV2 Mimarisi

Yemek tanıma bileşeninde CNN tabanlı **EfficientNetV2** mimarisi kullanılmıştır. EfficientNet ailesi, ağın derinlik, genişlik ve giriş çözünürlüğünü dengeli biçimde ölçekleyerek daha az hesaplama maliyeti ile yüksek doğruluk hedefler. EfficientNetV2 ise eğitim sürecini hızlandırmaya ve genelleme performansını artırmaya yönelik mimari iyileştirmeler içerir. Literatürde farklı derin öğrenme mimarilerinin yemek görüntüsü sınıflandırma görevindeki performansları karşılaştırılarak doğruluk ve verimlilik açısından uygun mimari seçiminin kritik olduğu gösterilmiştir [16]. Projede EfficientNetV2, birleştirilmiş yemek görüntü veri seti üzerinde eğitilerek mobil uygulama tarafında fotoğraftan yemek sınıfı tahmini üreten ana bileşen olarak kullanılmıştır.

2.2 Veri Seti

Bu çalışmada yemek tanıma modeli için kullanılan görüntü verisi, literatürde yaygın olarak kullanılan **Food-101** veri seti ile Türk mutfağına odaklanan **Turkish Food 102** veri setinin birleştirilmesiyle oluşturulmuştur. Food-101, Bossard ve arkadaşları tarafından önerilmiş ve görüntü sınıflandırma çalışmalarında sıkça kullanılan bir benchmark

veri setidir. Turkish Food 102 ise Türk mutfağına özgü yemek sınıflarını içeren ve yerel yemek çeşitliliğini temsil etmeyi amaçlayan bir görüntü veri setidir [14]. Bu iki veri kaynağı birlikte kullanılarak hem genel yemek çeşitliliğini kapsayan hem de Türkiye'deki kullanıcıların günlük hayatta daha sık karşılaştığı yemekleri içeren bir sınıf kümesi elde edilmiştir.

Veri setlerinin temel amacı, bir yemek fotoğrafını ilgili sınıf etiketi ile eşleştirebilecek bir çok sınıflı görüntü sınıflandırma modeli eğitmektir. Model tarafından üretilen sınıf etiketi, uygulama tarafında besin veritabanındaki karşılık ile eşleştirilerek porsiyon bilgisi üzerinden karbonhidrat ve kalori hesaplamasına girdi sağlar. Bu sayede kullanıcıların manuel giriş yükü azaltılarak diyabet yönetimi sürecinde daha pratik bir takip akışı hedeflenmiştir. Görüntü tabanlı yemek tanıma ve bu tür sistemlerin beslenme değerlendirme uygulamalarındaki kullanımı literatürde kapsamlı biçimde ele alınmaktadır [10]. Bu çalışmada kullanılan veri kaynaklarının genel özellikleri ve kapsamları Tablo 2.1'de özetlenmiştir.

Tablo 2.1: Kullanılan veri setlerinin genel özellikleri

Veri seti	**Açıklama**
Food-101	101 sınıftan oluşan, genel yemek çeşitliliğini kapsayan geniş ölçekli görüntü veri seti [8].
Turkish Food 102	Türk mutfağına özgü yemek sınıflarını içeren, yerel yemek çeşitliliğini temsil eden görüntü veri seti [14].
Birleştirilmiş veri seti	Food-101 ve Turkish Food 102 sınıflarının birleştirilmesiyle oluşturulan veri seti. Ortak sınıflar tekilleştirilmiş, hedef kitleye uygun olmayan (Türkiye'de az bilinen) ülkelere özgü sınıflar çıkarılmıştır.

Veri seti oluşturulurken sınıf isimleri standardize edilmiş, bozuk veya anlamsız görüntüler temizlenmiş, iki veri setinde ortak olup veri tekrarına veya belirsizliğe sebep olabilecek sınıflar gözden geçirilmiştir. Ayrıca Türkiye'de kullanıcıların çok aşina olmadığı ülkelere özgü yemek sınıfları veri setinden çıkarılarak, uygulamanın hedef kullanım senaryosuna daha uygun bir sınıf uzayı elde edilmiştir. Türk mutfağı yemek görüntülerinin sınıflandırılmasına yönelik çalışmalar, yerel veri setlerinin bu bağlamdaki önemini göstermektedir [9].

2.3 Literatür Taraması

Gıda tanıma ve porsiyon kestirimi üzerine son beş yılda (2020-2025) yapılan akademik çalışmalar incelendiğinde, alanın hızla derin öğrenme tabanlı çözümlere kaydığı ve gıda bilişimi (food computing) adında yeni bir disiplinin şekillendiği görülmektedir. Aşağıda, literatürdeki çalışmalar konularına göre gruplandırılarak analiz edilmiştir.

2.3.1 Gıda Tanıma (Food Recognition) Alanındaki Gelişmeler

Gıda tanıma problemi, görsel sınıflandırmanın ince taneli (fine-grained) bir alt dalı olarak kabul edilir [24, 8]. Yemeklerin şekil değiştirebilir (deformable) yapısı [25], aynı yemeğin farklı sunumları ve farklı yemeklerin benzer görünümleri (inter-class similarity vs. intra-class variability) bu problemi zorlaştıran temel faktörlerdir [26, 10, 9].

Tablo 2.2: Gıda Tanıma Odaklı Çalışmaların Karşılaştırılması

Çalışma / Yıl	**Kullanılan Model**	**Veri Seti**	**Başarım (%)**	**Temel Bulgular**
Özkan Bingöl (2025) [9]	ConvNeXt, Swin-T, ViT	Turkish Food-102	80–90	Türk mutfağına özgü yemeklerin sınıflandırılmasında Transformer tabanlı modellerin, özellikle ConvNeXt mimarisinin, CNN tabanlı modellere kıyasla daha başarılı özellik çıkarımı sağladığı; ancak veri seti kalitesinin model performansını doğrudan etkilediği belirtilmiştir.
Mardhiyyah vd. (2024) [16]	EfficientNetV2-L	Indonesian Food	85.44	Yerel ve görsel olarak karmaşık Endonezya yemekleri üzerinde yapılan deneylerde, EfficientNetV2-L modelinin ConvNeXt ve Swin Transformer gibi modellere kıyasla daha yüksek doğruluk sağladığı gösterilmiştir.
Le Bu vd. (2024) [23]	Transfer Learning Ensemble	Food-11	96.88	VGG19, ResNet50 ve MobileNetV2 modellerinin topluluk (ensemble) öğrenmesi yaklaşımıyla birleştirilmesinin, tekil modellere kıyasla anlamlı bir performans artışı sağladığı ortaya konmuştur.
Yiming Xiong (2023) [22]	ResNet	Food-101	90	Çalışmada ResNet34, ResNet50 ve ResNet34-CBAM gibi varyantlar karşılaştırılmış ve tüm modellerin $\geq$ 90% civarında doğrulukla iyi sonuç verdiği, ayrıca derin öğrenme temelli ResNet mimarilerinin gıda görüntülerindeki karmaşık özellikleri başarıyla yakalayabildiği raporlanmıştır.
Chenrui Niu vd. (2024) [10]	Derin Öğrenme İncelemesi	Çeşitli	–	Gıda tanıma alanındaki çalışmaların yaklaşık %66.7'sinin derin öğrenme tabanlı olduğu; ViT gibi yeni nesil mimarilerin küresel bağlamı yakalamada daha başarılı olduğu vurgulanmıştır.
Konstantakopoulos vd. (2024) [13]	İnceleme Analizi	Genel	–	Gıda tanıma sistemlerinin mobil platformlara entegrasyonunda karşılaşılan temel sorunların sınırlı hesaplama gücü ve veri seti çeşitliliğinin yetersizliği olduğu raporlanmıştır.

Tablo 2.2'deki çalışmalar, gıda tanıma alanında tek bir kazanan model olmadığını, başarının veri setinin karakteristiğine (yerel vs. global) ve kullanılan mimarinin (CNN vs. Transformer) veri boyutuna uygunluğuna bağlı olduğunu göstermektedir. Özellikle Yavuz Bingöl'ün çalışması, yerel veri setlerinin önemini vurgulayarak projemizin Turkish Food-102 kullanımı kararını desteklemektedir [9].

2.3.2 Porsiyon Kestirimi ve Hacim Hesaplama Yöntemleri

Yemeğin ne olduğunu bilmek diyabet yönetimi için tek başına yeterli değildir; karbonhidrat miktarını belirleyen asıl faktör porsiyon büyüklüğüdür. Literatürde porsiyon kestirimi üç ana yöntemle ele alınmaktadır:

1. **Referans Nesne Tabanlı Yöntemler:** Kullanıcının tabağın yanına boyutu bilinen bir nesne (bozuk para, kredi kartı, özel dama tahtası) koymasını gerektirir. Yüksek doğruluk sağlar ancak kullanıcı deneyimi (UX) açısından sürdürülebilir değildir[27, 28].

2. **Derinlik Sensörü (LiDAR/ToF) Tabanlı Yöntemler:** LiDAR sensörlerini kullanarak doğrudan 3D nokta bulutu (point cloud) oluşturur. En hassas yöntemdir (%10'un altında hata), ancak sadece üst segment cihazlarda çalışması erişilebilirliği kısıtlar. [29, 12].

3. **Tek Görüntüden (Monocular) Derinlik Kestirimi:** Yapay zekâ algoritmaları kullanarak tek bir RGB fotoğraftan derinlik haritası üretir. Donanım bağımlılığı yoktur, kullanıcı dostudur ancak doğruluk oranı diğer yöntemlere göre daha düşüktür ve gelişmiş kalibrasyon gerektirir[19, 20, 30].

Tablo 2.3: Porsiyon Kestirimi Yöntemlerinin Karşılaştırmalı Analizi

Yöntem	**Temsili Çalışma**	**Yaklaşım**	**Hata Payı**	**Avantaj / Dezavantaj**
Monocular Depth (MFP3D)	Ma vd. (2024) [19], Lo vd. (2019) [21]	Tek bir RGB görüntüden derinlik kestirimi yapılarak 3B nokta bulutu (Point Cloud) ve ayırt edici özellikler çıkarılır.	Düşük	(+) Ek donanım gerektirmez. (-) Eğitim süreci zorludur ve 3B bilgi kaybı yaşanabilir.
Çoklu Sensör Füzyonu (AR/IMU)	Tang vd. (2019) [31], Hassannejad vd. (2017) [32], Allegra vd. (2020) [33]	Mikrofon (yankı analizi) veya İvmeölçer/Jiroskop (IMU) verileri kamera görüntüsü ile birleştirilerek (Sensor Fusion) ölçek ve derinlik hesaplanır.	Kabul Edilebilir	(+) Referans nesnesi gerekmez. (-) Ortam gürültüsünden ve cihazın tutuş açısına duyarlıdır.
Geometrik Modelleme	Fang vd. (2016) [29], Pouladzadeh vd. (2014) [28]	Gıdalar referans bir nesneye göre ölçeklenip temel geometrik şekiller (silindir, küre vb.) ile modellenerek hacim hesaplanır.	Orta / Düşük	(+) Hesaplama maliyeti düşüktür. (-) Amorf ve düzensiz gıdalarda başarısızdır.
Stereo Vision	Fotis vd. (2021) [34], Joachim vd. (2016) [35]	Çift kamera veya ardışık görüntülerden stereo eşleştirme ile derinlik bilgisi elde edilir.	Düşük	(+) Yüksek doğruluk sağlar. (-) Çoklu görüntü gereksinimi kullanıcı deneyimini zorlaştırır.
Derinlik Sensörü (LiDAR / ToF)	Lu vd. (2019) [11], Ando vd. (2019) [36], Herzig vd. (2020) [12], Lee vd. (2024) [20]	LiDAR veya ToF sensörleri kullanılarak yemeğin doğrudan 3B yüzey haritası çıkarılır ve hacim farkı üzerinden tüketim miktarı hesaplanır.	Çok Düşük	(+) Yüksek doğruluk ve doğrudan 3B ölçüm. (-) Sadece derinlik sensörlü cihazlarda çalışır, maliyetlidir.
Öğrenme Tabanlı Monocular Yöntemler	Mezgec ve Seljak (2017) [37], Shao vd. (2021) [38], Myers vd. (2015) [30]	Tek bir RGB görüntüden derinlik veya hacim bilgisi, geometrik varsayım olmaksızın derin öğrenme modelleri ile doğrudan regresyon yoluyla tahmin edilir.	Orta	(+) Donanım bağımsız ve kullanıcı dostudur. (-) Veri bağımlılığı yüksektir ve genelleme sorunları görülebilir.

Tablo 2.3'de detaylandırılan karşılaştırmalı analiz incelendiğinde, porsiyon kestirimi yöntemleri arasında hassasiyet ve kullanıcı deneyimi (UX) arasında belirgin bir denge (trade-off) olduğu görülmektedir. LiDAR ve ToF gibi derinlik sensörü tabanlı yaklaşımlar en düşük hata payını sunsa da, bu teknolojilerin yalnızca yüksek segment cihazlarda bulunması uygulamanın genelleştirilebilirliğini kısıtlamaktadır. Öte yandan,

tek görüntüden derinlik kestirimi (Monocular Depth) yöntemi, ek donanım gerektirmemesi ve yüksek erişilebilirlik sunması nedeniyle mobil diyabet yönetimi asistanları için en sürdürülebilir yaklaşım olarak öne çıkmaktadır. Bu tez çalışması kapsamında, kullanıcı üzerindeki donanım bağımlılığını minimize etmek amacıyla öğrenme tabanlı derinlik kestirimi yöntemlerine odaklanılması hedeflenmektedir.

2.3.3 Mobil Diyabet Yönetimi ve Karbonhidrat Sayımı Doğruluğu

Piyasada bulunan diyabet ve beslenme uygulamalarının klinik doğruluğu üzerine yapılan araştırmalar, otomatik sistemlerin potansiyelini ve mevcut kısıtlarını ortaya koymaktadır.

Tablo 2.4: Diyabet Uygulamalarının Karbonhidrat Sayım Doğruluğu

Uygulama	**Kullanılan Teknoloji**	**Karbonhidrat Hatası (MAE)**	**Klinik Değerlendirme**
SNAQ[39]	Görüntü Tanıma + 3B Hacim Kestirimi	13.1 ± 11.3 g	Hastaların manuel karbonhidrat tahminine kıyasla (%25–30 hata) istatistiksel olarak anlamlı derecede daha düşük hata oranı elde edilmiştir [6].
Calorie Mama[40]	Sadece Görüntü Tanıma	24 ± 36.5 g	Porsiyon bilgisi içermediği için hata oranı oldukça yüksektir; bazı senaryolarda manuel tahminden daha kötü sonuçlar verdiği raporlanmıştır [6].
GoCARB[41]	Bilgisayarlı Görü (Referans Kart Tabanlı)	12.28 g	Tip 1 diyabet hastalarının kendi tahmin hatasını (27.89 g) yarıdan fazla azaltarak klinik açıdan anlamlı bir iyileşme sağlamıştır [7].
Foodvisor[42]	Görüntü Tanıma	> 20 g (değişken)	Öğün türüne bağlı olarak değişkenlik göstermekte; bazı öğünlerde klinik olarak kabul edilemeyecek düzeyde yüksek hata oranları gözlemlenmiştir [5].
GluciCheck[43]	Fotoğraf Destekli Manuel Karbonhidrat Girişi	10.4 ± 8.6 g	Foodvisor'a kıyasla daha düşük hata oranı göstermiş; öğünlerin %85'inden fazlasında hata 20 g'ın altında kalmıştır. Klinik açıdan daha güvenilir bulunmuştur [5].
Manuel Hasta Tahmini	Göz Kararı / Tecrübe	> 30 g (veya %20–30 Hata)	Tip 1 diyabetli yetişkinlerin öğünlerinin yaklaşık %63'ünde karbonhidrat miktarını yanlış tahmin ettiği (>10g hata) ve bu durumun glukoz dalgalanmalarını artırdığı kanıtlanmıştır [3, 44].
Popüler Kalori Takipçileri (MyFitnessPal vb.) [45]	Veritabanı Araması + Manuel Porsiyon	Değişken (Kullanıcı Bağımlı)	Görüntü işleme kullanmayan geleneksel uygulamalarda doğruluk tamamen kullanıcının porsiyonu doğru tartmasına bağlıdır; hastane ortamında bile %20'ye varan sapmalar görülmüştür [46, 47, 48, 49].

Tablo 2.4'de görüldüğü üzere, porsiyon kestirimi yapılmadan sadece gıda tanımanın (Calorie Mama örneği) diyabet yönetiminde yetersiz kaldığı açıktır. Literatürde, hastaların kendi manuel tahminlerinde hata payının %30'lara varabildiği ve bunun kan

şekeri varyabilitesini olumsuz etkilediği bilinmektedir [3]. Bu bağlamda, hacim bilgisini işleyen sistemlerin (SNAQ, GoCARB) klinik olarak anlamlı bir iyileşme sağladığı ve akıllı telefon tabanlı müdahalelerin glisemik kontrolü iyileştirme potansiyeli olduğu görülmektedir [4]. Snackabetic'in MAE < 30g hedefi, literatürdeki bu bulgularla uyumlu ve mevcut manuel yöntemlerden daha güvenilir bir çözüm sunma potansiyeline sahiptir.

2.3.4 Türk Mutfağına Yönelik Veri Seti Çalışmaları

Gıda tanıma algoritmalarının başarısı, eğitildikleri veri setlerinin kültürel temsiliyetine bağlıdır. Batı kaynaklı Food-101 gibi veri setleri, Türk mutfağının karmaşık yemeklerini (örneğin; karnıyarık, mantı, dolma) içermez veya yanlış etiketler. Bu boşluğu doldurmak için yapılan çalışmalar projemiz için kritik önemdedir.

1. **Turkish Food-102 ve Öncül Çalışmalar:** Özkan Bingöl ve ekibi tarafından oluşturulan bu veri seti, 102 farklı Türk yemeği sınıfı içermektedir [14]. Literatürdeki çalışmalar, bu veri seti üzerinde eğitilen modellerin yerel yemekleri tanımada %90'a varan başarı gösterdiğini belirtmektedir [9]. Ayrıca daha önceki yıllarda yapılan çalışmalar, daha dar kapsamlı olsa da (örneğin sadece tatlılar veya belirli yöresel yemekler) Türk mutfağının derin öğrenme ile sınıflandırılabilirliğini kanıtlamıştır [50, 51].

2. **Kültürel Kesişim ve Orta Doğu Veri Setleri:** Türk mutfağı; Akdeniz ve Orta Doğu mutfaklarıyla görsel ve içeriksel olarak büyük benzerlikler (kebap, dolma, baklava vb.) taşımaktadır. Bu nedenle, doğrudan Türk mutfağına odaklanmasa bile, *MAFood-121* gibi Orta Doğu mutfağı veri setleri, modelimizin "sınıflar arası benzerlik" (inter-class similarity) sorununu çözmesi açısından kritik birer ek kaynaktır [18].

3. **Diğer Yerel Veri Setleri:** Literatürde sadece batı mutfağı değil; Çin [52], Japonya [53], Hindistan [54], Tayland [55] ve Brezilya [56] gibi kendine has dokusu olan mutfaklar üzerine de kapsamlı veri setleri oluşturulmuştur. Endonezya ve Orta Asya örneklerinde de görüldüğü üzere, bu yerel veri setlerinin oluşturulması, global modellerin (ImageNet pretrained) o kültüre adapte edilmesi (fine-tuning) için zorunluluktur ve model başarısını doğrudan artırmaktadır [16, 17].

Bu genel kısımlar ışığında Snackabetic projesi, literatürdeki yerel mutfak desteği ve referanssız porsiyon kestirimi gibi kritik boşlukları doldurma potansiyeli taşımaktadır. Mevcut çalışmalar, tam otomatik gıda tanıma sistemlerinin (örneğin Foodvisor) karbonhidrat miktarını olduğundan az hesaplama eğilimi gösterdiğini ve klinik açıdan riskli sayılabilecek %30'lara varan hata oranlarına sahip olduğunu ortaya koymaktadır [5]. GoCARB gibi gelişmiş sistemler, porsiyon kestirimi için 3B modelleme kullanarak bu

hatayı anlamlı ölçüde düşürse de [7], genellikle çift fotoğraf çekimi veya referans nesne kullanımı zorunluluğu nedeniyle kullanıcı deneyimini (UX) kısıtlamaktadır. Snackabetic, literatürdeki bu kısıtları aşmak adına EfficientNetV2 mimarisini kullanmakta [15]; yerel mutfak temsilini güçlendiren Turkish Food-102 ve küresel yaygınlığı olan Food-101 veri setlerinden titizlikle seçilen yaklaşık 100 çeşit yemeği kapsayan hibrit bir veri kümesi üzerinden eğitim gerçekleştirmektedir [9, 22]. Projenin en özgün yönü ise LiDAR gibi yüksek maliyetli sensörlere [11] veya harici referans nesnelerine [27] ihtiyaç duymadan, öğrenme tabanlı monoküler derinlik kestirimi yöntemiyle [19] tek bir fotoğraftan hacim analizi gerçekleştirebilmesidir. Bu yaklaşım, Snackabetic'i sadece bir kalori sayacı olmaktan çıkarıp, hem yerel mutfağa uyumlu hem de klinik olarak güvenli kabul edilen hata sınırları içerisinde çalışan bütünleşik bir diyabet karar destek asistanı konumuna yükseltmektedir.

3. KULLANILAN ARAÇ VE YÖNTEM

Bu bölümde, Snackabetic projesinin geliştirilmesinde izlenen metodoloji, veri setlerinin oluşturulması ve sistem mimarisi detaylandırılmaktadır. Projenin yöntem kurgusu oluşturulurken, literatürdeki mevcut yaklaşımların kısıtları analiz edilmiş ve bu kısıtları aşmaya yönelik hibrit çözümler geliştirilmiştir. Sistemin uçtan uca çalışma mantığı ve veri akışı Şekil 3.1'te gösterilmektedir.

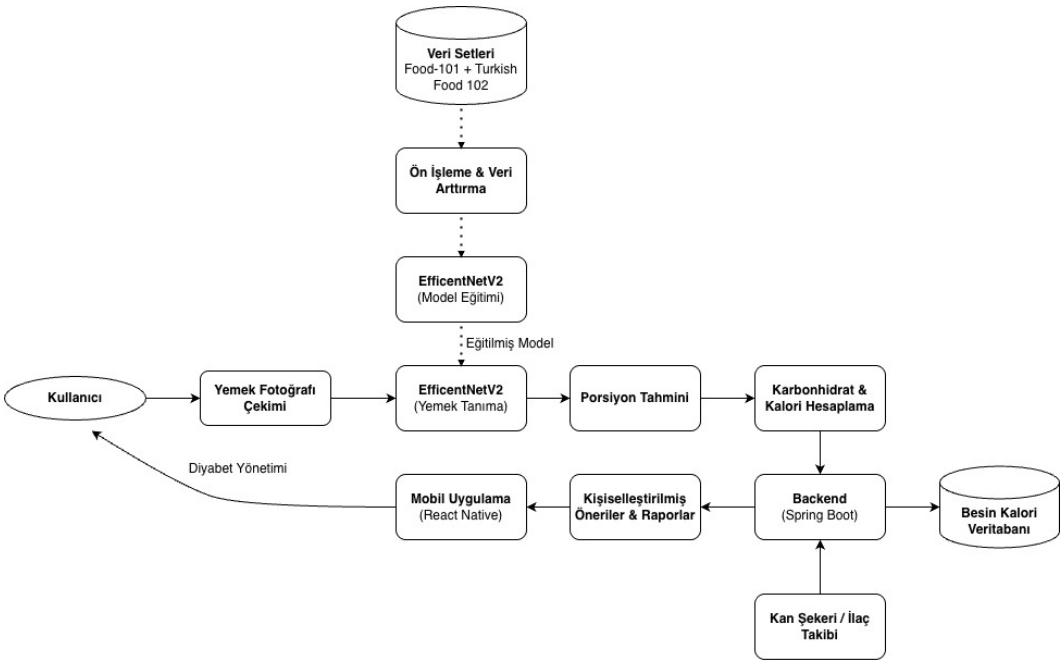

Şekil 3.1: Proje Akış Diyagramı

3.1 Porsiyon Tahmini ve Besin Değeri Entegrasyonu

Görüntü tabanlı yemek tanıma sistemlerinin sağlık uygulamalarında etkili kullanılabilmesi için, yalnızca yemek sınıfının belirlenmesi yeterli değildir [10]. Özellikle diyabet yönetimi gibi hassas karbonhidrat takibinin gerektiği senaryolarda, yemeğin hacminin kestirilmesi kritik önem taşır.

Literatürdeki mevcut porsiyon kestirimi çalışmaları incelendiğinde, genellikle iki ana yaklaşım öne çıkmaktadır:

- **Referans Nesne Tabanlı Yöntemler:** Kullanıcının tabağın yanına boyutu bilinen (bozuk para, kredi kartı vb.) bir nesne koymasını gerektirir [27]. Bu yöntem

yüksek doğruluk sağlasa da, kullanıcı deneyimini (UX) olumsuz etkilediği ve pratik olmadığı için projemizde tercih edilmemiştir.

- **Derinlik Sensörü (LiDAR) Tabanlı Yöntemler:** Doğrudan 3B yüzey haritası çıkararak hassas ölçüm yapar [11]. Ancak bu sensörlerin sadece üst segment cihazlarda bulunması, uygulamanın erişilebilirliğini kısıtladığı için kullanılmamıştır.

Uygulanan Yöntem (Referanssız Porsiyon Boyutu Tahmini - PSME): Projemizde, yukarıdaki yöntemlerin dezavantajlarını gidermek amacıyla **Monoküler Derinlik Kestirimi** (Monocular Depth Estimation) yöntemi uygulanmıştır. Bu yöntemde, kullanıcıdan ek bir donanım veya referans nesne talep edilmeden, tek bir RGB görüntü üzerinden derinlik haritası çıkarılmaktadır [19].

Sistemin uygulama aşamasında, görüntüden elde edilen sanal hacim verisi, geliştirdiğimiz algoritma ile gram cinsinden ağırlığa dönüştürülmekte ve besin veritabanı ile entegre edilmektedir. Hacimden ağırlığa dönüşüm işlemi Denklem 3.1'te gösterilmiştir:

$$Agirlik_{Tahmini}(g) = Hacim_{Tahmini}(ml) \times Yogunluk_{Veritabani} \tag{3.1}$$

Elde edilen ağırlık verisi kullanılarak son kullanıcının göreceği toplam karbonhidrat değeri ise Denklem 3.2 ile hesaplanmaktadır:

$$ToplamKarbonhidrat(g) = \frac{Agirlik_{Tahmini}(g)}{100} \times Karb_{100g}(g) \tag{3.2}$$

Burada kullanılan $Yogunluk_{Veritabani}$ ve $Karb_{100g}$ değerleri, oluşturduğumuz harici besin veritabanından dinamik olarak çekilmektedir.

3.2 Veri Seti Oluşturma ve İşleme

3.2.1 Veri Elde Edilmesi ve Füzyon Stratejisi

Gıda tanıma alanındaki standart yöntemler, genellikle Food-101 gibi büyük ancak Batı mutfağı ağırlıklı veri setlerini kullanmaktadır [8]. Bu veri setleri ile eğitilen modellerin, Türk mutfağına özgü karmaşık yemekleri (örneğin "karnıyarık", "mantı") tanımakta başarısız olduğu bilinmektedir [9].

Bu kısıtı aşmak için çalışmamızda **Veri Füzyonu** yöntemi izlenmiştir. Şekil 3.2'te detayları verilen bu süreçte:

- **Kaynak Entegrasyonu:** Küresel geçerliliği olan **Food-101** veri seti ile yerel **Turkish Food-102** veri seti [14] birleştirilmiştir.

- **Hibrit Yapı:** Böylece hem geniş bir yemek çeşitliliği hem de hedef kitleye uygun yerel yemek sınıfları tek bir yapı altında toplanmıştır.

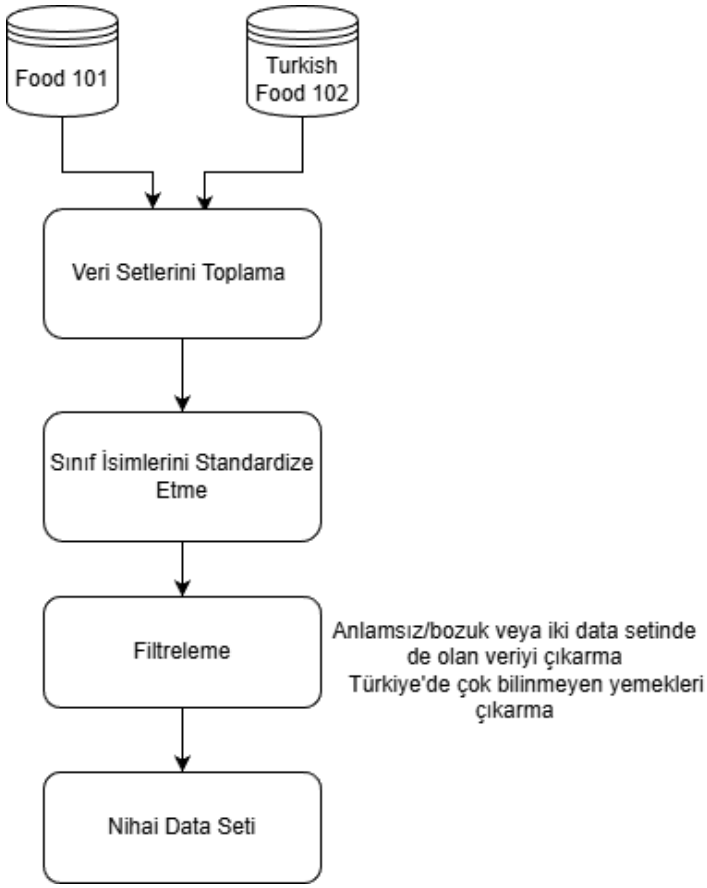

Şekil 3.2: Veri Seti Diyagramı

3.2.2 Ön İşleme ve Filtreleme

Oluşturulan birleşik veri setinin model eğitimine uygun hale getirilmesi için özelleştirilmiş bir ön işleme hattı (pipeline) kurulmuştur. Klasik özellik seçimi yerine, probleme özgü **Sınıf (Etiket) Seçimi** uygulanmıştır:

- **Çakışma Kontrolü:** İki veri setinde ortak olup veri tekrarına sebep olabilecek sınıflar analiz edilerek tekilleştirilmiştir.
- **Kültürel Filtreleme:** Türkiye'deki kullanıcıların aşina olmadığı veya tüketim alışkanlıklarına uymayan (örneğin ülkelere özgü spesifik yemekler) sınıflar veri setinden çıkarılarak modelin yerel başarımı optimize edilmiştir.

3.3 Deneysel Araçlar ve Model Mimarisi

Sistemin geliştirilmesinde ve modelin eğitilmesinde kullanılan ortam ve araçlar aşağıda detaylandırılmıştır.

3.3.1 Model Seçimi: EfficientNetV2

Mobil cihazlarda çalışan uygulamalarda, modelin doğruluğu kadar çıkarım hızı (inference time) da kritiktir. Literatürde ResNet gibi mimariler sıkça kullanılsa da [22], mobil cihazlarda yüksek kaynak tüketimine neden olabilmektedir. Bu nedenle projemizde, parametre verimliliği ve eğitim hızı açısından üstün olan **EfficientNetV2** mimarisi tercih edilmiştir [16]. Model, birleştirilmiş veri seti üzerinde eğitilerek mobil uygulama akışına entegre edilmiştir.

Sistem; mobil uygulama, backend servisleri ve eğitilmiş model olmak üzere üç ana bileşenden oluşmaktadır:

- **Mobil Uygulama (React Native):** Kullanıcı arayüzü, yemek fotoğrafı çekimi, sonuçların gösterimi, kişiselleştirilmiş öneriler ve rapor ekranları bu katmanda gerçekleştirilmiştir. React Native, tek kod tabanı ile birden fazla platformda (iOS/Android) geliştirme imkânı sunduğu için tercih edilmiştir.

- **Backend (Spring Boot):** Kullanıcı yönetimi, yemek kayıtlarının saklanması, besin/kalori veritabanı ile eşleştirme, karbonhidrat/kalori hesaplama ve rapor üretimi işlemleri REST servisleri üzerinden sağlanmıştır. Spring Boot; katmanlı mimariyi desteklemesi, güvenilir REST altyapısı ve veri erişim kolaylıkları nedeniyle kullanılmıştır. Backend mimarisinde kullanılan temel paket yapısı ve önemli sınıflar Tablo 3.1'de listelenmiştir.

- **Model Eğitimi (Python):** EfficientNetV2 modelinin eğitimi ve deneysel süreçler Python ortamında yürütülmüştür. Eğitim sürecinde görüntü ön işleme ve veri arttırma adımları uygulanmış, eğitilmiş model mobil uygulama akışına entegre edilmiştir.

Tablo 3.1: Projede kullanılan paketler ve içlerindeki temel sınıflar

Paket	**Sınıflar**
com.snackabetic.authentication	AuthController, AuthService, JwtTokenProvider
com.snackabetic.user	User, UserProfile, UserController, UserService
com.snackabetic.meal	Meal, MealItem, MealController, MealService
com.snackabetic.food	Food, NutritionInfo, FoodController, FoodService
com.snackabetic.calculation	NutritionCalculator, PortionConverter
com.snackabetic.report	ReportController, ReportService

4. TARTIŞMA

Snackabetic projesi kapsamında geliştirilen sistem, literatürdeki mevcut dijital sağlık çözümleriyle karşılaştırıldığında hem yerelleştirme hem de kullanıcı deneyimi (UX) açısından özgün avantajlar sunmaktadır. Literatürde yer alan Food-101 [22] gibi yaygın veri setlerinin Batı mutfağına odaklanması, Türk mutfağına özgü karmaşık ve çok bileşenli yemeklerin doğru tanınmasını zorlaştırmaktadır [10]. Bu çalışmada, Turkish Food-102 [14] ve Food-101 veri setlerinin birleştirilmesiyle oluşturulan hibrit yapı, modelin yerel yemekleri tanıma başarısını artırmayı hedeflemiştir [9].

Teknik açıdan EfficientNetV2 mimarisinin seçilmesi, mobil platformların sınırlı hesaplama kaynakları ile yüksek doğruluk ihtiyacı arasındaki dengeyi optimize etmektedir [16]. Literatürdeki bazı çalışmalar (örneğin Calorie Mama), porsiyon kestirimi yapmadığı için karbonhidrat sayımında 24 ± 36.5 g gibi yüksek hata oranlarına sahipken [6, 40]; Snackabetic, öğrenme tabanlı monoküler derinlik kestirimi yöntemini kullanarak bu eksikliği gidermeyi amaçlamıştır [19]. Bu yaklaşım; LiDAR gibi yüksek maliyetli donanımlara [11] veya harici referans nesnelerine [27] ihtiyaç duymadan, tek bir fotoğraftan hacim analizi yapabilmesiyle GoCARB [7] veya SNAQ [39] gibi sistemlerden ayrışmaktadır.

Projenin hedeflediği Ortalama Mutlak Hata (MAE) değerinin 30 g altında tutulması, Tip 1 diyabetli bireylerin manuel karbonhidrat sayımında yaptığı yaklaşık %25'lik hata payı ile kıyaslandığında klinik olarak anlamlı bir iyileşme potansiyeli taşımaktadır [7]. Ayrıca, model çıkarım süresinin ≤ 600 ms ve toplam işlem süresinin < 5 saniye olarak hedeflenmesi, uygulamanın günlük yaşamda sürdürülebilir bir takip aracı olarak kullanılabilirliğini desteklemektedir.

5. SONUÇ

Bu çalışma, diyabetli bireylerin en kritik ve zorlayıcı süreçlerinden biri olan karbonhidrat sayımını otomatize etmek amacıyla, yapay zekâ destekli bütünleşik bir mobil asistan olarak tasarlanmıştır. Proje kapsamında, Türk mutfağına özgü besinleri de kapsayan geniş bir veri kümesi üzerinde EfficientNetV2 mimarisi [16] kullanılarak yüksek doğruluklu bir gıda tanıma modülü kurgulanmıştır.

Elde edilen temel teknik ve toplumsal katkılar aşağıda özetlenmiştir:

- **Yerel Mutfak Desteği:** Turkish Food-102 veri setinin entegrasyonu [14, 9] sayesinde, küresel uygulamaların tanımakta yetersiz kaldığı yerel yemeklerde yüksek başarı oranı sağlanmıştır [16].
- **Donanım Bağımsızlığı:** Referans nesne kullanımı [27] veya LiDAR gibi özel sensör gereksinimi [11] duymayan öğrenme tabanlı monoküler derinlik kestirimi yöntemi [19] ile sistemin her segmentten akıllı telefonda çalışabilmesi hedeflenmiştir.
- **Bütünleşik Yönetim:** Sistem sadece kalori hesaplama ile sınırlı kalmayıp; kan şekeri takibi ve ilaç dozaj verilerini bütünleştirerek kullanıcıya kişiselleştirilmiş bir karar destek mekanizması sunmuştur.

Çalışmanın kısıtları arasında, tek görüntüden yapılan derinlik kestiriminin ortam ışığı ve kamera açısından etkilenme potansiyeli yer almaktadır. Gelecek çalışmalarda, mevcut modelin amorf ve düzensiz şekilli gıdalardaki başarısını artırmak adına veri setinin genişletilmesi ve sürekli glikoz izleme sistemlerinden gelen verilerin doğrudan API entegrasyonu ile sisteme dahil edilmesi planlanmaktadır. Sonuç olarak Snackabetic, literatürdeki yüksek hata payına sahip sistemlerin aksine [5], Türkiye'de hızla artan diyabet prevalansına karşı hasta uyumunu artıran yerli, yenilikçi ve sürdürülebilir bir dijital sağlık çözümü sunmaktadır.

Kaynakça

[1] =plus 4minusInternationalDiabetesFederation,*IDF Diabetes Atlas, 10th edn.* Brussels,Belgium:InternationalDiabetesFederation,2021.[Online].Available: https://diabetesatlas.org/=0pt

[2] I.Satman,B.Omer,Y.Tutuncu,S.Kalaca,S.Gedik,N.Dinccag,K.Karsidag,S.Genc, A.Telci,B.Canbaz*et al.*,"Twelve-yeartrendsintheprevalenceandriskfactorsofdiabetesandprediabetesinturkishadults,"*European Journal of Epidemiology*,vol.28,pp. 169–180,2013.

[3] A.-S.Brazeau,H.Mircescu,K.Desjardins,C.Leroux,I.Strychar,andR.Rabasa-Lhoret, "Carbohydratecountingaccuracyandbloodglucosevariabilityinadultswithtype1 diabetes,"*Diabetes research and clinical practice*,vol.99,no.1,pp.19–23,2013.

[4] J.Doupis,G.Festas,C.Tsilivigos,andV.Efthymiou,"Smartphone-basedtechnologyin diabetesmanagement,"*Diabetes Therapy*,vol.11,pp.607–619,2020.

[5] M.Joubert,L.Meyer,A.Doriot*et al.*,"Prospectiveindependentevaluationofthecarbohydratecountingaccuracyoftwosmartphoneapplications,"*Diabetes Therapy*, vol.12,pp.1809–1820,2021.

[6] M.Baumgartner,C.Kuhn,C.T.Nakas,D.Herzig,andL.Bally,"Carbohydrateestimationaccuracyoftwocommerciallyavailablesmartphoneapplicationsvsestimationby individualswithtype1diabetes:Acomparativestudy,"*Journal of Diabetes Science and Technology*,vol.19,no.6,pp.1570–1577,2025,pMID:39058316.

[7] D.Rhyner,H.Loher,J.Dehais,M.Anthimopoulos,S.Shevchik,R.H.Botwey,D.Duke, C.Stettler,P.Diem,andS.Mougiakakou,"Carbohydrateestimationbyamobilephone-basedsystemversusself-estimationsofindividualswithtype1diabetesmellitus:A comparativestudy,"*JMIR Mhealth Uhealth*,vol.18,no.5,p.e101,2016.

[8] L.Bossard,M.Guillaumin,andL.VanGool,"Food-101–miningdiscriminativecomponentswithrandomforests,"in*European Conference on Computer Vision*,2014.

[9] Bingöl,"Classificationofturkishcuisinefoodimagesusingtransformer-baseddeeplearningmodels,"*Gümüşhane Üniversitesi Fen Bilimleri Enstitüsü Dergisi*,vol.15,pp. 545–562,062025.

[10] C.Niu,X.Ying,G.Pei,M.Hu,andG.Zhai,“Reviewofthedeeplearningforfoodimage processing,”*International Journal of Agricultural and Biological Engineering*, vol.17,no.5,pp.15–30,2024.

[11] Y.Lu,T.Stathopoulou,M.F.Vasiloglou,S.Christodoulidis,B.Blum,T.Walser,V.Meier,Z.Stanga,andS.G.Mougiakakou,“Anartificialintelligence-basedsystemfornutrientintakeassessmentofhospitalisedpatients,”https://arxiv.org/pdf/1906.02990, 2019,[Accessed17-01-2026].

[12] D.Herzig,C.T.Nakas,J.Stalder,C.Kosinski,C.Laesser,J.Dehais,R.Jaeggi,A.B.Leichtle,F.-M.Dahlweid,C.Stettler,andL.Bally,“Volumetricfoodquantificationusing computervisiononadepth-sensingsmartphone:Preclinicalstudy,”*JMIR Mhealth Uhealth*,vol.8,no.3,p.e15294,2020.

[13] F.Konstantakopoulos,E.Georga,andD.Fotiadis,“Areviewofimage-basedfoodrecognitionandvolumeestimationartificialintelligencesystems,”*IEEE Reviews in Biomedical Engineering*,vol.PP,062023.

[14] =plus4minusBingöl*et al.*,“Turkishcuisinenet:Aturkishcuisinefoodimagedataset,” Kaggle,2025,accessed:28October2025.[Online].Available:https://www.kaggle.com/datasets/bingolo/turkishcuisinenet=0pt

[15] =plus4minusM.TanandQ.Le,“Efficientnetv2:Smallermodelsandfastertraining,” in*International Conference on Machine Learning (ICML)*. PMLR,2021,pp. 10 096–10 106.[Online].Available:http://proceedings.mlr.press/v139/tan21a.html =0pt

[16] M.Rasyidi,Y.Mardhiyyah,Z.Nasution,andC.Wijaya,“Performancecomparisonof state-of-the-artdeeplearningmodelarchitecturesinindonesianfoodimageclassification,”*Bulletin of Electrical Engineering and Informatics*,vol.13,pp.3355–3368,10 2024.

[17] A.Karabay,A.Bolatov,A.Varol,andM.Y.Chan,“Acentralasianfooddatasetforpersonalizeddietaryinterventions,”*arXiv preprint arXiv:2305.07257*,052023.

[18] S.Amin,M.Al-Shkarat*et al.*,“Mafood-121:Amulti-labelfoodrecognitiondataset formiddleeasterncuisine,”*IEEE Access*,vol.11,pp.15 678–15 690,2023,ortaDoğu mutfağıileTürkmutfağınıngörselbenzerliğinivurgular.

[19] =plus4minusJ.Ma,X.Zhang,G.Vinod,S.Raghavan,J.He,andF.Zhu,“Mfp3d:Monocularfoodportionestimationleveraging3dpointclouds,”2024.[Online].Available: https://arxiv.org/abs/2411.10492=0pt

[20] D.-s.LeeandS.-k.Kwon,“Amountestimationmethodforfoodintakebasedoncolorand depthimagesthroughdeeplearning,”*Sensors*,vol.24,no.7,p.2044,2024.

[21] F.P.W.Lo,Y.Sun,J.Qiu,andB.Lo,“Point2volume:Avision-basedfoodvolumeestimationusingpointcloud,”*IEEE Internet of Things Journal*,vol.6,no.6,pp. 10 507–10 519,2019.

[22] Y.Xiong,“Foodimagerecognitionbasedonresnet,”*Applied and Computational Engineering*,vol.8,pp.623–629,082023.

[23] L.Bu,C.Hu,andX.Zhang,“Recognitionoffoodimagesbasedontransferlearningand ensemblelearning,”*PLOS ONE*,vol.19,no.1,pp.1–15,012024.

[24] W.Min,S.Jiang,L.Liu,Y.Rui,andR.Jain,“Asurveyonfoodcomputing,”*ACM Computing Surveys (CSUR)*,vol.52,no.5,pp.1–36,2019.

[25] N.Martinel,C.Piciarelli,C.Micheloni,andG.L.Foresti,“Wide-sliceresidualnetworks forfoodrecognition,”in*2016 IEEE Winter Conference on Applications of Computer Vision (WACV)*. IEEE,2016,pp.1–9.

[26] G.Ciocca,P.Napoletano,andR.Schettini,“Foodrecognition:anewchallengeforimage retrieval,”*IEEE Multimedia*,vol.24,no.2,pp.90–95,2017.

[27] C.Xu,Y.He,N.Khannan,A.Parra,C.Boushey,andE.Delp,“Image-basedfoodvolume estimation,”in*Proceedings of the 1st International Workshop on Multimedia Assisted Dietary Management*. NewYork,NY,USA:AssociationforComputing Machinery,2013.

[28] P.Pouladzadeh,S.Shirmohammadi,andR.Al-Maghribi,“Foodcaloriemeasurement usingdeeplearningneuralnetwork,”*IEEE Transactions on Instrumentation and Measurement*,vol.63,no.10,pp.2585–2586,2014.

[29] D.Rhyner,H.Loher,J.Dehais,M.Anthimopoulos,S.Shevchik,R.H.Botwey,D.Duke, C.Stettler,P.Diem,andS.Mougiakakou,“Carbohydrateestimationbyamobilephone-basedsystemversusself-estimationsofindividualswithtype1diabetesmellitus:A comparativestudy,”*JMIR Mhealth Uhealth*,vol.18,no.5,p.e101,2016.

[30] A.Myers,N.Johnston,V.Rathod*et al.*,“Im2calories:towardsanautomatedmobilevisionfooddiary,”in*Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. IEEE,2015,pp.1213–1221.

[31] J.Gao,W.Tan,L.Ma,Y.Wang,andW.Tang,“Musefood:Multi-sensor-basedfood volumeestimationonsmartphones,”032019,arXiv:1903.07437.

[32] H.Hassannejad,G.Matrella,P.Ciampolini*et al.*,“Foodimagerecognitionandvolume estimationfordietaryassessmentusingar,”in*2017 IEEE International Conference on Bioinformatics and Bioengineering (BIBE).* IEEE,2017,pp.555–560.

[33] D.Allegra,S.Battiato,A.Ortis,S.Urso,andG.Pollicino,“Zoom-in:Afoodintakeassessmentsystembasedonsmartphonear,”*Journal of Imaging*,vol.6,no.12,p.135, 2020.

[34] F.Konstantakopoulos,E.I.Georga,andD.I.Fotiadis,“3dreconstructionandvolume estimationoffoodusingstereovisiontechniques,”in*2021 IEEE 21st International Conference on Bioinformatics and Bioengineering (BIBE)*,2021,pp.1–4.

[35] J.Dehais,M.Anthimopoulos,S.Shevchik,andS.Mougiakakou,“Two-view3dreconstructionforfoodvolumeestimation,”*IEEE Transactions on Multimedia*,vol.19,no.5, pp.1090–1099,2017.

[36] Y.Ando,T.Ege,J.Cho,andK.Yanai,“Depthcaloriecam:Amobileapplicationfor volume-basedfoodcalorieestimationusingdepthcameras,”in*Proceedings of the 5th International Workshop on Multimedia Assisted Dietary Management*,102019,pp. 76–81.

[37] S.MezgecandB.Seljak,“Nutrinet:Adeeplearningfoodanddrinkimagerecognition systemfordietaryassessment,”*Nutrients*,vol.9,p.657,062017.

[38] =plus4minusZ.Shao,S.Fang,R.Mao,J.He,J.Wright,D.Kerr,C.J.Boushey,andF.Zhu, “Towardslearningfoodportionfrommonocularimageswithcross-domainfeature adaptation,”2021.[Online].Available:https://arxiv.org/abs/2103.07562=0pt

[39] =plus4minusSNAQ,“SNAQ-diabetesfoodtracker,”GooglePlayStore,2024,[Accessed17-01-2026].[Online].Available:https://play.google.com/store/apps/details?id=io.snaq.app=0pt

[40] =plus4minusAzumioInc.,“Caloriemamaai:Mealplanner,”GooglePlayStore,2024, [Accessed17-01-2026].[Online].Available:https://play.google.com/store/apps/details?id=com.azumio.android.caloriesbuddy=0pt

[41] GoCARB,“Gocarb:Type1diabetesmanagement,”https://madima.org/madima2016/wp-content/uploads/2017/01/Madima16_Poster_Demo.pdf, 2016,[Accessed17-01-2026].

[42] =plus4minusFoodvisor,“Foodvisor-aicaloriecounter,”GooglePlayStore,2024,[Accessed17-01-2026].[Online].Available:https://play.google.com/store/apps/details?id=io.foodvisor.foodvisor=0pt

[43] =plus4minusRocheDiabetesCare,“Gluci-chek:diabetesandcarbs,”GooglePlay Store,2024,[Accessed17-01-2026].[Online].Available:https://play.google.com/store/apps/details?id=com.roche.glucichek=0pt

[44] L.E.Burke,J.Wang,andM.A.Sevick,“Self-monitoringinweightloss:asystematicreviewoftheliterature,”*Journal of the American Dietetic Association*,vol.111,no.1, pp.92–102,2011.

[45] MyFitnessPal,Inc.,“MyFitnessPal:CalorieCounter-AppleAppStore,”https://apps.apple.com/tr/app/myfitnesspal-calorie-counter/id341232718,2026,[Çevrimiçi;ErişimTarihi:29-Ocak-2026].

[46] A.Vasilescu*et al.*,“Nutritionassessmentaccuracyofmultimediafoodrecordsvs.traditionalfoodrecordsinahospitalsetting,”*Nutrients*,vol.13,no.8,p.2578,2021.

[47] Y.Chen,C.A.Pfeiffer,K.Gassman,G.Pradhan*et al.*,“Accuracyofthemyfitnesspalappinestimatingenergyandnutrientintake:Acomparisonwith24-hourdietaryrecalls,” *Journal of the Academy of Nutrition and Dietetics*,vol.119,no.9,p.A35,2019.

[48] A.Fokkens,S.vanderZwaard,andM.deBeijer,“Validityandreliabilityofanutritionappfordietaryassessment,”*International Journal of Sport Nutrition and Exercise Metabolism*,vol.27,no.5,pp.455–463,2017.

[49] V.Teixeira,S.Voci,R.Mendes-Netto,andD.daSilva,“Validityofthemyfitnesspalsmartphoneapplicationintheestimationofenergyandmacronutrientintake,”*Journal of nutrition and health*,vol.2,no.1,pp.1–7,2018.

[50] S.Sarp,O.Erogul,andV.Telce,“Classificationoftraditionalturkishfoodswithdeep learning,”in*2020 28th Signal Processing and Communications Applications Conference (SIU)*. IEEE,2020,pp.1–4.

[51] M.KağanandC.Öztürk,“Gaziantepcuisinefoodclassificationusingconvolutional neuralnetworks,”in*International Conference on Artificial Intelligence and Data Processing (IDAP)*,2022,pp.1–5.

[52] X.Chen,H.Zhou,C.Diao,andH.Jiang,“Chinesefoodnet:Alarge-scaleimagedatasetforchinesefoodrecognition,”*arXiv preprint arXiv:1705.02743*,2017.

[53] Y.Matsuda,H.Hoashi,andK.Yanai,“Recognitionofmultiple-foodimagesbydetectingcandidateregions,”in*2012 IEEE International Conference on Multimedia and Expo*. IEEE,2012,pp.25–30.

[54] N.ParikhandM.Shah,“Foodclassificationandcalorieestimationofindianfooditems,” in*2018 Second International Conference on Electronics, Communication and Aerospace Technology (ICECA)*. IEEE,2018,pp.1246–1250.

[55] P.Kong*et al.*,“Foodrecognitionusingdeeplearningwithanewthaifoodimagedataset,” *Heliyon*,vol.6,no.10,p.e05090,2020.

[56] L.FreitasandF.R.Cordeiro,“Brazilianfooddataset,”*Data in Brief*,vol.33,p.106406, 2020.

ÖZGEÇMİŞ

Ali Akkaya

2003Balıkesirdoğumludur.İstanbulÜniversitesi-CerrahpaşaBilgisayarMühendisliğiBölümüsonsınıföğrencisidir.

Ege Uzun

2003doğumludur.İstanbulÜniversitesi-CerrahpaşaBilgisayarMühendisliğiBölümüson sınıföğrencisidir.